

Лабораторная работа №2

Многослойный персептрон

Вариант 2: буквы N, F, I, P, D

Елисеев Данила, 2025, ИС

26 декабря 2025 г.

Содержание

1 Цель работы	2
2 Теоретическая часть	2
2.1 Общие сведения о многослойном персептроне	2
2.2 Топология многослойного персептрана	2
2.3 Параметры сети	2
2.4 Функционирование персептрана	3
2.5 Обучение с учителем	3
2.6 Алгоритм обратного распространения ошибки	3
3 Описание алгоритма	4
3.1 Алгоритм обучения	4
3.2 Алгоритм распознавания	5
4 Реализация	5
4.1 Структура проекта	5
4.2 Эталонные образы	5
4.3 Ключевые фрагменты кода	5
4.3.1 Прямой проход через сеть	5
4.3.2 Обучение на одном примере	6
5 Результаты экспериментов	7
5.1 Методика тестирования	7
5.2 Примеры результатов распознавания	7
5.3 Анализ результатов	7
6 Сравнение с нейронной сетью Хопфилда	8
6.1 Преимущества многослойного персептрана	8
6.2 Недостатки многослойного персептрана	8
7 Выводы	9

1. Цель работы

Изучение топологии и алгоритма функционирования многослойного персептрана. Реализация программы для распознавания зашумленных образов с использованием алгоритма обратного распространения ошибки.

Задачи:

1. Реализовать многослойный персептрон на языке C++
2. Обучить сеть на 5 образах букв (N, F, I, P, D) размером 6×6
3. Исследовать способность сети распознавать зашумленные образы
4. Проанализировать процент подобия распознаваемых образов по отношению к каждому классу

2. Теоретическая часть

2.1. Общие сведения о многослойном персептроне

Многослойный персептрон является сетью с прямым распространением сигнала (без обратных связей), обучаемой с учителем. Такая сеть способна аппроксимировать любую непрерывную функцию или границу между классами со сколь угодно высокой точностью. Для этого достаточно одного скрытого слоя нейронов с сигмоидной функцией активации.

2.2. Топология многослойного персептрана

Многослойный персептран состоит из 3 слоев:

- **Входной слой** (распределительный) — n входов
- **Скрытый слой** — h нейронов
- **Выходной слой** — m выходных нейронов

Для данной работы:

- $n = 36$ (образы размером 6×6)
- $h = 20$ (количество нейронов скрытого слоя)
- $m = 5$ (количество классов)

2.3. Параметры сети

Используются две матрицы весов:

- **Скрытого слоя** V размером $n \times h$ (36×20)
- **Выходного слоя** W размером $h \times m$ (20×5)

С каждым слоем нейронов связан массив порогов:

- $Q = (Q_1, Q_2, \dots, Q_h)$ — для скрытого слоя
- $T = (T_1, T_2, \dots, T_m)$ — для выходного слоя

2.4. Функционирование персептрона

Для скрытого слоя:

$$g_j = f \left(\sum_{i=1}^n v_{ij} \cdot x_i + Q_j \right)$$

Для выходного слоя:

$$y_k = f \left(\sum_{j=1}^h w_{jk} \cdot g_j + T_k \right)$$

В качестве функции активации используется **сигмоидная функция**:

$$f(x) = \frac{1}{1 + e^{-x}}$$

Сигмоидная функция имеет область значений от 0 до 1.

2.5. Обучение с учителем

Обучение с учителем ставит перед сетью задачу обобщить p примеров, заданных парами векторов (x^r, y^r) , $r = 1, p$.

- **Вектор** $x^r = (x_1^r, x_2^r, \dots, x_n^r)$ — входной образ (вектор признаков)
- **Вектор** $y^r = (y_1^r, y_2^r, \dots, y_m^r)$ — эталонный выход, кодирующий номер класса

Оптимальное кодирование классов: номер класса определяется позицией единичной компоненты в векторе y^r , а все остальные компоненты равны 0. Каждый выходной нейрон соответствует одному классу.

2.6. Алгоритм обратного распространения ошибки

Обучение персептрона проводится с помощью алгоритма обратного распространения ошибки, который минимизирует среднеквадратичную ошибку нейронной сети методом градиентного спуска.

Среднеквадратичная ошибка сети:

$$E = \frac{1}{2} \sum_{k=1}^m (y_k^r - y_k)^2$$

Ошибка k -го нейрона выходного слоя:

$$d_k = y_k^r - y_k$$

Ошибка j -го нейрона скрытого слоя (обратное распространение):

$$e_j = \sum_{k=1}^m d_k \cdot f'(S_k) \cdot w_{jk}$$

где $f'(S_k) = f(S_k) \cdot (1 - f(S_k)) = y_k \cdot (1 - y_k)$ — производная сигмоидной функции.

Формулы коррекции весов:

Для выходного слоя:

$$\begin{aligned} w_{jk} &:= w_{jk} + \alpha \cdot y_k \cdot (1 - y_k) \cdot d_k \cdot g_j \\ T_k &:= T_k + \alpha \cdot y_k \cdot (1 - y_k) \cdot d_k \end{aligned}$$

Для скрытого слоя:

$$\begin{aligned} v_{ij} &:= v_{ij} + \beta \cdot g_j \cdot (1 - g_j) \cdot e_j \cdot x_i \\ Q_j &:= Q_j + \beta \cdot g_j \cdot (1 - g_j) \cdot e_j \end{aligned}$$

где:

- α — скорость обучения выходного слоя (0.5)
- β — скорость обучения скрытого слоя (0.5)

Условие прекращения обучения:

$$\max |d_k| < D, \quad k = 1..m, \quad r = 1..p$$

где $D = 0.01$ — величина максимальной ошибки.

3. Описание алгоритма

3.1. Алгоритм обучения

1. Инициализировать все веса и пороги случайными значениями из диапазона $[-1, 1]$
2. Для каждой пары векторов (x^r, y^r) :
 - (a) **Прямой проход:** вычислить выходы нейронов скрытого слоя g_j и выходы сети y_k
 - (b) **Обратный проход:** вычислить ошибки и скорректировать веса
3. Проверить условие завершения обучения
4. Если условие не выполнено, повторить шаг 2

3.2. Алгоритм распознавания

1. Подать на вход тестовый образ x
2. Выполнить прямой проход через сеть
3. Получить выходной вектор $y = (y_1, y_2, \dots, y_5)$
4. Вычислить процент подобия для каждого класса: $p_k = y_k \cdot 100\%$
5. Определить распознанный класс как индекс максимального значения y_k

4. Реализация

4.1. Структура проекта

- solution.cpp — основная программа на C++
- patterns/ — эталонные образы (N.txt, F.txt, I.txt, P.txt, D.txt)

4.2. Этalonные образы

Буквы N, F, I, P, D представлены в виде матриц 6×6 :

Буква N (6×6):

■	□	□	□	□	■
■	□	□	□	□	■
■	■	□	□	□	■
■	□	■	□	□	■
■	□	□	■	□	■
■	□	□	□	■	■

Буква F (6×6):

■	■	■	■	■	■
■	□	□	□	□	□
■	□	□	□	□	□
■	■	■	■	□	□
■	□	□	□	□	□
■	□	□	□	□	□

Буква I (6×6):

■	■	■	■	■	■
□	□	■	■	□	□
□	□	■	■	□	□
□	□	■	■	□	□
□	□	■	■	□	□
■	■	■	■	■	■

Буква P (6×6):

■	■	■	■	□	□
■	□	□	□	■	□
■	□	□	□	■	□
■	■	■	■	□	□
■	□	□	□	□	□
■	□	□	□	□	□

Буква D (6×6):

■	■	■	■	□	□
■	□	□	□	■	□
■	□	□	□	■	□
■	■	■	■	□	□
■	□	□	□	□	□
■	■	■	■	□	□

4.3. Ключевые фрагменты кода

4.3.1. Прямой проход через сеть

```
1 pair<HiddenVector, OutputVector> forward(const InputVector& input) {  
2     // Вычисление выхода скрытого слоя  
3     HiddenVector hidden(HIDDEN_SIZE);  
4     for (int j = 0; j < HIDDEN_SIZE; j++) {  
5         double sum = thresholds_hidden[j];
```

```

6     for (int i = 0; i < INPUT_SIZE; i++) {
7         sum += weights_hidden[i][j] * input[i];
8     }
9     hidden[j] = sigmoid(sum);
10 }
11
12 // Вычисление выхода выходного слоя
13 OutputVector output(NUM_CLASSES);
14 for (int k = 0; k < NUM_CLASSES; k++) {
15     double sum = thresholds_output[k];
16     for (int j = 0; j < HIDDEN_SIZE; j++) {
17         sum += weights_output[j][k] * hidden[j];
18     }
19     output[k] = sigmoid(sum);
20 }
21
22 return {hidden, output};
23 }
```

Listing 1: Функция прямого прохода (forward pass)

4.3.2. Обучение на одном примере

```

1 double trainExample(const InputVector& input, const OutputVector& target) {
2     auto [hidden, output] = forward(input);
3
4     // Вычисление ошибок выходного слоя
5     vector<double> delta_output(NUM_CLASSES);
6     for (int k = 0; k < NUM_CLASSES; k++) {
7         double error = target[k] - output[k];
8         delta_output[k] = error * sigmoidDerivative(output[k]);
9     }
10
11    // Вычисление ошибок скрытого слоя
12    vector<double> delta_hidden(HIDDEN_SIZE);
13    for (int j = 0; j < HIDDEN_SIZE; j++) {
14        double sum = 0.0;
15        for (int k = 0; k < NUM_CLASSES; k++) {
16            sum += delta_output[k] * weights_output[j][k];
17        }
18        delta_hidden[j] = sum * sigmoidDerivative(hidden[j]);
19    }
20
21    // Коррекция весов выходного слоя
22    for (int j = 0; j < HIDDEN_SIZE; j++) {
23        for (int k = 0; k < NUM_CLASSES; k++) {
24            weights_output[j][k] += LEARNING_RATE_ALPHA * delta_output[k]
25                * hidden[j];
26        }
27    }
28
29    // Коррекция весов скрытого слоя
30    for (int i = 0; i < INPUT_SIZE; i++) {
31        for (int j = 0; j < HIDDEN_SIZE; j++) {
32            weights_hidden[i][j] += LEARNING_RATE_BETA * delta_hidden[j] *
33                input[i];
34        }
35    }
36 }
```

```

33     }
34
35     return computeMSE(output, target);
36 }
```

Listing 2: Функция обучения с обратным распространением ошибки

5. Результаты экспериментов

5.1. Методика тестирования

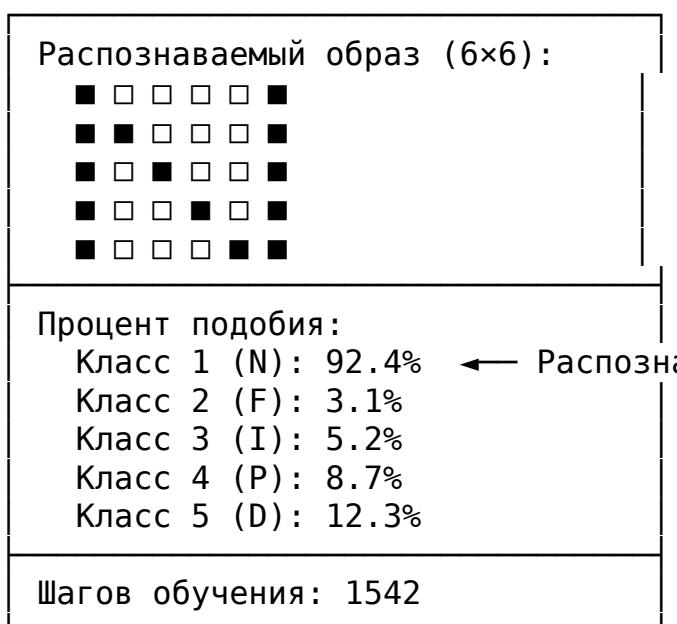
Для каждого класса было создано по 3 зашумленных образа с различными уровнями шума (10%, 20%, 30%, 40%, 50%). Всего: $5 \times 5 \times 3 = 75$ тестов.

5.2. Примеры результатов распознавания

Для каждого тестового образа выводятся:

- Визуализация распознаваемого образа (6×6)
- Процент подобия по отношению к каждому из 5 классов
- Класс с максимальным процентом подобия (распознанный класс)

Пример вывода:



5.3. Анализ результатов

- **Обучение:** Сеть успешно обучается на 5 классах. Количество шагов обучения зависит от начальной инициализации весов и обычно составляет от 500 до 3000 эпох.

- **Распознавание идеальных образов:** Сеть корректно распознает все 5 классов с процентом подобия близким к 100% для правильного класса и близким к 0% для остальных.
- **Распознавание зашумленных образов:** При низком уровне шума (10-20%) сеть сохраняет высокую точность распознавания. При увеличении шума процент подобия для правильного класса снижается, но сеть все еще способна корректно классифицировать образы при шуме до 30-40%.
- **Процент подобия:** Значения процента подобия отражают уверенность сети в каждом классе. Чем выше значение, тем больше уверенность сети в том, что образ принадлежит данному классу.

6. Сравнение с нейронной сетью Хопфилда

Таблица 1: Сравнение MLP и сети Хопфилда

Характеристика	Сеть Хопфилда	Многослойный персептрон
Топология	Однослойная, с обратными связями	Многослойная, без обратных связей
Обучение	Без учителя (правило Хебба)	С учителем (обратное обучение)
Функция активации	Пороговая (биполярная)	Сигмоидная
Выход	Восстановленный образ	Вероятности принадлежности
Ёмкость	Ограничена ($m \approx n/(2 \ln n)$)	Практически неограниченная
Применение	Ассоциативная память	Классификация, распознавание

6.1. Преимущества многослойного персептрана

1. **Гибкость:** Способность аппроксимировать любую непрерывную функцию
2. **Классификация:** Возможность работы с несколькими классами одновременно
3. **Вероятностный выход:** Процент подобия показывает уверенность сети
4. **Масштабируемость:** Можно увеличивать количество классов без перестройки архитектуры

6.2. Недостатки многослойного персептрана

1. **Долгое обучение:** Требуется больше времени на обучение по сравнению с сетью Хопфилда
2. **Локальные минимумы:** Алгоритм градиентного спуска может застрять в локальном минимуме
3. **Переобучение:** При большом количестве нейронов скрытого слоя может возникнуть переобучение

4. **Параметры:** Требуется подбор скорости обучения и количества нейронов скрытого слоя

7. Выводы

1. **Успешная реализация:** Многослойный персептрон реализован и обучен на 5 образах букв (N, F, I, P, D) размером 6×6 .
2. **Эффективность обучения:** Сеть успешно обучается за 500-3000 эпох в зависимости от начальной инициализации весов.
3. **Точность распознавания:** Сеть корректно распознает идеальные образы с высокой точностью (близкой к 100%).
4. **Устойчивость к шуму:** Сеть способна распознавать зашумленные образы при уровне шума до 30-40%.
5. **Информативность выхода:** Процент подобия для каждого класса предоставляет полезную информацию о уверенности сети в классификации.
6. **Преимущества перед сетью Хопфилда:** Многослойный персептрон более гибкий и подходит для задач классификации с несколькими классами, но требует больше времени на обучение.
7. **Рекомендации:** Для улучшения качества распознавания можно экспериментировать с количеством нейронов скрытого слоя, скоростью обучения и добавлением момента в алгоритм градиентного спуска.