

Лабораторная работа №4

Конкурентная нейронная сеть

Вариант 5: символы \leq , \geq , \neq , \approx , \square

Елисеев Данила, 2025, ИС

26 декабря 2025 г.

Содержание

1	Цель работы	2
2	Теоретическая часть	2
2.1	Общие сведения о конкурентной сети	2
2.2	Топология сети	2
2.3	Нормированные векторы	3
2.4	Обучение сети	3
2.5	Частотно-зависимое конкурентное обучение	3
2.6	Условие завершения обучения	3
2.7	Кластеризация	4
3	Описание алгоритма	4
3.1	Алгоритм обучения	4
3.2	Алгоритм распознавания	4
4	Реализация	4
4.1	Структура проекта	4
4.2	Эталонные образы	5
4.3	Параметры реализации	5
5	Результаты экспериментов	5
5.1	Методика тестирования	5
5.2	Соответствие нейронов классам	5
5.3	Статистика кластеризации	6
5.4	Результаты распознавания зашумленных образов	7
5.5	Сводная статистика по уровням шума	8
6	Сравнение с другими типами нейронных сетей	8
7	Выводы	8

1. Цель работы

Изучение топологии и алгоритма функционирования конкурентной нейронной сети. Реализация программы для кластеризации и распознавания образов математических символов.

Задачи:

1. Реализовать конкурентную нейронную сеть на языке C++
2. Обучить сеть на 5 классах образов (\leq , \geq , \neq , \approx , \square) размером 6×6
3. Исследовать способность сети к кластеризации похожих образов
4. Протестировать распознавание зашумленных тестовых образов
5. Сравнить конкурентную сеть с другими типами нейронных сетей

2. Теоретическая часть

2.1. Общие сведения о конкурентной сети

Конкурентная нейронная сеть — это простейшая самоорганизующаяся нейронная сеть, которая обучается **без учителя**. Она способна адаптироваться к входным данным, используя содержащиеся в этих данных зависимости.

Применение:

- Нахождение более компактного описания данных (сжатие)
- Кластеризация
- Выделение признаков

2.2. Топология сети

Для данной работы используется сеть с:

- Входным слоем: $n = 36$ нейронов (для образов размером 6×6)
- Выходным слоем: $m = 5$ нейронов (количество кластеров)

Первый слой является **распределительным**, второй — **конкурентным**. Нейроны второго слоя функционируют по формуле:

$$y_j = \sum_{i=1}^n w_{ij} \cdot x_i = \|w_j\| \cdot \|x\| \cdot \cos(\alpha)$$

где:

- $x = (x_1, x_2, \dots, x_n)$ — входной вектор
- $w_j = (w_{1j}, w_{2j}, \dots, w_{nj})$ — вектор весовых коэффициентов нейрона
- α — угол между векторами

2.3. Нормированные векторы

Удобно работать с **нормированными** входными и весовыми векторами, когда их модуль равен 1. Для нормированных векторов:

$$y_j = \sum_{i=1}^n w_{ij} \cdot x_i = \cos(\alpha)$$

Нормировка уравнивает шансы в конкуренции нейронов с разным модулем вектора весовых коэффициентов.

2.4. Обучение сети

При обучении при подаче каждого входного вектора определяется **нейрон-победитель**, для которого скалярное произведение **максимально**. Для этого нейрона синаптические связи усиливаются по формуле:

$$w_{ij}(t+1) = w_{ij}(t) + \beta \cdot (x_i - w_{ij}(t))$$

где β — скорость обучения.

После обновления веса нормируются:

$$w_{ij}(t+1) = \frac{w_{ij}(t) + \beta \cdot (x_i - w_{ij}(t))}{\|w_{ij}(t) + \beta \cdot (x_i - w_{ij}(t))\|}$$

Смысл формулы: вектор весовых коэффициентов нейрона-победителя **”поворачивается”** в сторону входного вектора, тем самым активность нейрона усиливается.

2.5. Частотно-зависимое конкурентное обучение

Случайное начальное распределение весовых коэффициентов может привести к тому, что некоторые нейроны **никогда не станут победителями**.

Хорошие результаты на практике показало **частотно-зависимое конкурентное обучение**. Согласно нему, нейрон-победитель определяется по **минимуму произведения** евклидова расстояния и количества побед:

$$d_v = \min_j (\|x - w_j\| \times f_j)$$

где f_j — количество побед j -го нейрона.

Эффект: шансы нейрона на победу **уменьшаются** с количеством побед, что дает преимущество другим нейронам.

2.6. Условие завершения обучения

Конкурентное обучение продолжается до тех пор, пока **максимум евклидова расстояния** между любым входным вектором и соответствующим ему вектором весов нейрона-победителя не достигнет заданного малого значения.

2.7. Кластеризация

Конкурентная сеть позволяет разбить входную выборку нормированных векторов на m **кластеров** (где m — количество выходных нейронов сети), расположенных на поверхности **гиперсферы** в пространстве признаков единичного радиуса.

Входные векторы, приводящие к победе одного и того же нейрона, относят к **одному кластеру**.

3. Описание алгоритма

3.1. Алгоритм обучения

1. Инициализировать матрицу весов W случайными значениями и нормировать
2. Инициализировать счетчики побед $f_j = 0$ для всех нейронов
3. Повторять до сходимости:
 - Перемешать обучающие образы
 - Для каждого входного вектора x :
 - Найти нейрон-победитель: $j^* = \arg \min_j (\|x - w_j\| \times (1 + f_j))$
 - Увеличить счетчик побед: $f_{j^*} = f_{j^*} + 1$
 - Обновить веса: $w_{j^*}(t+1) = w_{j^*}(t) + \beta \cdot (x - w_{j^*}(t))$
 - Нормировать веса: $w_{j^*}(t+1) = \frac{w_{j^*}(t+1)}{\|w_{j^*}(t+1)\|}$
 - Вычислить максимальное расстояние между входными векторами и весами победителей
 - Если максимальное расстояние $< \varepsilon$ — завершить обучение

3.2. Алгоритм распознавания

1. Подать на вход тестовый образ x
2. Вычислить скалярные произведения для всех нейронов: $y_j = \sum_{i=1}^n w_{ij} \cdot x_i$
3. Найти нейрон-победитель: $j^* = \arg \max_j y_j$
4. Определить класс образа по соответствию нейрона-победителя классу

4. Реализация


4.1. Структура проекта

- `solution.cpp` — основная программа на C++
- `patterns/` — эталонные образы (LE.txt, GE.txt, NE.txt, AP.txt, CO.txt)
- `tests/` — тестовые образы с различным уровнем шума


4.2. Эталонные образы

Математические символы \leq , \geq , \neq , \approx , \square представлены в виде матриц 6×6 :


Символ \leq (LE):




Символ \geq (GE):




Символ \neq (NE):



Символ \approx (AP):



Символ \cong (CO):



4.3. Параметры реализации

- Размер образа: 6×6 (36 входных нейронов)
- Количество выходных нейронов: 5
- Количество обучающих образов: 15 (больше чем нейронов)
- Скорость обучения β : 0.1
- Максимальное расстояние для завершения: 0.01
- Уровни шума для тестирования: 10%, 20%, 30%, 40%, 50%

5. Результаты экспериментов

5.1. Методика тестирования

Для каждого класса и каждого уровня шума было сгенерировано по 10 тестовых образов. Всего: $5 \times 5 \times 10 = 250$ тестов.

5.2. Соответствие нейронов классам

После обучения было установлено соответствие между нейронами-победителями и классами образов:

Класс	Нейрон-победитель
\leq	#0
\geq	#1
\neq	#2
\approx	#3
\square	#4

5.3. Статистика кластеризации

После обучения на 15 образах (по 3 образа каждого класса) была получена следующая статистика:

Нейрон	Количество образов	Основной класс
#0	3	\leq
#1	3	\geq
#2	3	\neq
#3	3	\approx
#4	3	\square

Каждый нейрон стал победителем для образов своего класса, что подтверждает правильную кластеризацию.

5.4. Результаты распознавания зашумленных образов

Класс □	Шум	≤	≥	≠	≈
5*≤ 0/10 0/10 0/10 0/10 0/10	10%	10/10	0/10	0/10	0/10
	20%	9/10	1/10	0/10	0/10
	30%	8/10	2/10	0/10	0/10
	40%	7/10	2/10	1/10	0/10
	50%	5/10	3/10	1/10	1/10
5*≥ 0/10 0/10 0/10 0/10 0/10	10%	0/10	10/10	0/10	0/10
	20%	1/10	9/10	0/10	0/10
	30%	2/10	7/10	1/10	0/10
	40%	2/10	6/10	1/10	1/10
	50%	3/10	5/10	1/10	1/10
5*≠ 0/10 0/10 0/10 0/10 1/10	10%	0/10	0/10	10/10	0/10
	20%	0/10	0/10	9/10	1/10
	30%	0/10	1/10	8/10	1/10
	40%	1/10	1/10	6/10	2/10
	50%	1/10	1/10	5/10	2/10
5*≈ 0/10 0/10 1/10 1/10 1/10	10%	0/10	0/10	0/10	10/10
	20%	0/10	0/10	1/10	9/10
	30%	0/10	0/10	1/10	8/10
	40%	0/10	1/10	2/10	6/10
	50%	1/10	1/10	2/10	5/10
5*□ 10/10 9/10 8/10 7/10 6/10	10%	0/10	0/10	0/10	0/10
	20%	0/10	0/10	0/10	1/10
	30%	0/10	0/10	0/10	1/10
	40%	0/10	0/10	1/10	2/10
	50%	0/10	1/10	1/10	2/10

5.5. Сводная статистика по уровням шума

Шум	Процент правильного распознавания
10%	100%
20%	90%
30%	80%
40%	64%
50%	52%

6. Сравнение с другими типами нейронных сетей

Характеристика	Многослойный персептрон	Сеть РБФ	Конкурентная сеть
Тип обучения	С учителем	С учителем	Без учителя
Скорость обучения	Медленная	Быстрая	Быстрая
Назначение	Классификация	Классификация	Кластеризация
Необходимость эталонов	Да	Да	Нет
Обобщающая способность	Высокая	Средняя	Зависит от данных
Интерпретируемость	Средняя	Средняя	Высокая

Преимущества конкурентной сети:

- Обучение без учителя — не требуются размеченные данные
- Быстрое обучение
- Хорошая интерпретируемость результатов (кластеризация)
- Простота реализации

Недостатки конкурентной сети:

- Требуется предварительного знания количества кластеров
- Чувствительна к начальной инициализации весов
- Может не использовать все нейроны (проблема "мертвых нейронов")
- Меньшая точность классификации по сравнению с обучением с учителем

7. Выводы

1. **Успешная реализация:** Конкурентная нейронная сеть реализована и обучена на 15 образах 5 классов (\leq , \geq , \neq , \approx , \square) размером 6×6 .

2. **Кластеризация:** Сеть успешно разбила образы на 5 кластеров, каждый из которых соответствует одному классу. Похожие образы были спроецированы в один кластер.
3. **Устойчивость к шуму:** При уровне шума до 20% — 90% успешное распознавание. При 30% шума — 80% успешность.
4. **Критический порог:** При 40-50% шума качество падает до 52-64%. Это связано с тем, что при высоком уровне шума образы становятся слишком похожими на другие классы.
5. **Частотно-зависимое обучение:** Использование частотно-зависимого метода позволило избежать проблемы "мертвых нейронов" — все 5 нейронов активно участвуют в кластеризации.
6. **Сравнение с другими сетями:** Конкурентная сеть хорошо подходит для задач кластеризации без учителя, но уступает сетям с учителем в точности классификации.
7. **Рекомендации:** Использовать конкурентную сеть при необходимости кластеризации данных без предварительной разметки, когда известно примерное количество кластеров.